

Same adapters. Different memory.

긴 입력에서도, 4-bit는 유리할까요?

한 모델 · 한 데이터 파이프라인

01 / EVIDENCE

출발점은 두 논문

LoRA [1]

기반 가중치는 고정합니다.
저랭크 갱신을 학습합니다.

QLoRA [2]

고정 기반을 4-bit로 저장하고
저랭크 어댑터를 학습합니다.

HYPOTHESIS / 미검증

긴 입력의 다른 메모리 성분이
상대적 절감 폭을 줄일까요?

02 / THE CONTROLLED CONTRAST



03 / KEEP FIXED

01 모델과 데이터

체크포인트 · 토큰나이저 · 분할

02 학습 조건

어댑터 · 토큰 예산 · 선택 규칙

03 실행과 측정

장비 · 버전 · 측정 구간

정밀도별 커널 차이는 기록합니다.

04 / EVALUATION PLAN

256 / 512 / 1,024 tokens

후보 길이입니다. 지원 범위와 파일럿 후 확정합니다.

Peak allocated / reserved memory

Held-out NLL · 처리량 · OOM도 함께 기록합니다.

품질 허용폭과 반복 수는 독립 확인 전에 정합니다.

05 / WHAT WOULD CHANGE OUR MIND?

절감 + 품질 기준 충족

평가한 설정에서 채택을 검토합니다.

절감 + 품질 기준 미달

메모리만으로 유용성을 결론 내리지 않습니다.

불확실 / 한 조건이 OOM

결론을 유보하거나 실행 경계를 보고합니다.

미정인 입력 / 모델 · 데이터 · 장비 · 품질 허용폭 · 반복 수 · 논의 가능한 초안이며 실행 전 확인이 필요합니다.

[1] Hu et al. / LoRA v2, abstract (2021) [2] Dettmers et al. / QLoRA v1, abstract & §2 (2023)

점선 = 계획 조건 · 화살표 = 비교 절차 · 도형 크기는 메모리 비율이 아닙니다. 자세한 조건은 proposal.md를 확인해 주세요.